Statistiques mathématiques : cours 7

Guillaume Lecué

23 septembre 2015

Cours précédent (rappels)

1. <u>vocabulaire</u> : accepter, rejeter, zone de rejet, erreur de 1ère et 2-ième espèces, niveau d'un test, fonction puissance, p-value, test UPP

 <u>résultat</u>: construction du test de Neyman-Pearson grâce au rapport de vraisemblance pour les problèmes de tests à hypothèses simples – propriété UPP des tests de Neyman-Pearson

Test UPP dans une famille à rapport de vraisemblance monotone

Rappels sur Neyman-Pearson

On a montré que le test de Neyman-Pearson est UPP pour un test de la forme :

$$H_0: \theta = \theta_0 \text{ contre } H_1: \theta = \theta_1$$

ce test est de la forme

$$\varphi_{\alpha}(Z) = \begin{cases}
H_0 & \text{si } f(\theta_1, Z) \leq c_{\alpha} f(\theta_0, Z) \\
H_1 & \text{sinon}
\end{cases}$$

où c_{α} est tel que (quand il y a une solution)

$$\mathbb{P}_{\theta_0}\left[f(\theta_1,Z)>c_{\alpha}f(\theta_0,Z)\right]=\alpha$$

Alors:

- 1. φ_{α} est de niveau α
- 2. φ_{α} est le test le plus puissant parmi tous les tests de niveau α



Famille à rapport de vraisemblance monotone (1/2)

On va construire un test UPP pour les problèmes de test de la forme :

$$H_0: \theta \leq \theta_0 \text{ contre } H_1: \theta > \theta_0$$

quand le rapport de vraisemblance a une structure particulière. On considère le cadre suivant :

- $\mathcal{E} = (\mathfrak{Z}, \mathcal{Z}, {\mathbb{P}_{\theta} : \theta \in \Theta})$: une expérience statistique
- ▶ Z : une observation dans cette expérience
- \blacktriangleright on suppose que $\Theta\subset\mathbb{R}$ est un intervalle ouvert
- ▶ le modèle est dominé par μ tel que $f(\theta,z)=\frac{d\,\mathbb{P}_{\theta}}{d\mu}(z)>0$, pour μ -presque tout $z\in\mathfrak{Z}$.



Famille à rapport de vraisemblance monotone (2/2)

Définition

On dit que la famille de densités $\{f(\theta,\cdot):\theta\in\Theta\}$ est à rapport de vraisemblance monotone s'il existe une statistique T(Z) telle que

$$\forall \theta_1 < \theta_2, \quad rac{f(\theta_2, Z)}{f(\theta_1, Z)}$$
 est une fonction monotone de $T(Z)$

ex. : quand $Z=(X_1,\ldots,X_n)$ où $X_i \overset{i.i.d.}{\sim} \mathcal{N}(\theta,1)$, le rapport de vraisemblance pour $\theta_1 < \theta_2$

$$\frac{f(\theta_2, Z)}{f(\theta_1, Z)} = \exp\left(\frac{n}{\sigma^2}(\theta_2 - \theta_1)\overline{X}_n\right) \exp\left(\frac{-n}{2\sigma^2}(\theta_2^2 - \theta_1^2)\right)$$

est une fonction croissante de $T(Z) = \overline{X}_n$.

Test UPP – théorème de Lehmann

Soit $\{f(\theta,\cdot):\theta\in\Theta\}$ une famille vérifiant les hypothèses précédantes et à rapport de vraisemblance monotone, par exemple croissante en T(Z). Soit $\alpha\in(0,1)$. On suppose que pour $\theta_0\in\Theta$, il existe $\rho(\theta_0,\alpha)$ tel que

$$\mathbb{P}_{\theta_0}\left[T(Z) > \rho(\theta_0, \alpha)\right] = \alpha$$

alors le test de région de rejet

$$\mathcal{R}^{\star} = \{z \in \mathfrak{Z} : T(z) > \rho(\theta_0, \alpha)\}$$

est

- 1. de niveau α
- 2. le plus puissant parmi tous les tests de niveau α pour le problème de test

$$H_0: \theta \leq \theta_0$$
 contre $H_1: \theta > \theta_0$



Exemple de test UPP

Pour $Z = (X_1, \dots, X_n)$ où $X_i \stackrel{i.i.d.}{\sim} \mathcal{N}(\theta, 1)$, le rapport de vraisemblance

$$\frac{f(\theta_2,Z)}{f(\theta_1,Z)} = \exp\left(\frac{n}{\sigma^2}(\theta_2 - \theta_1)\overline{X}_n\right) \exp\left(\frac{-n}{2\sigma^2}(\theta_2^2 - \theta_1^2)\right)$$

est une fonction croissante de $T(Z) = \overline{X}_n$. Alors pour le problème de test

$$H_0: \theta \leq \theta_0$$
 contre $H_1: \theta > \theta_0$

le test de région de rejet

$$\boxed{\mathcal{R}^* = \{(x_1, \ldots, x_n)^\top \in \mathbb{R}^n : \bar{x}_n > \theta_0 + t_{n,\alpha}\}}$$

où $t_{n,\alpha}$ est tel que $\mathbb{P}_{\theta_0}[\overline{X}_n > \theta_0 + t_{n,\alpha}] = \alpha$ (càd $t_{n,\alpha} = q_{1-\alpha}/\sqrt{n}$), est une test de niveau α , UPP.



objectifs: niveau asymptotique et consistance

 $id\acute{e}$: Les tests UPP sont très rares. En général, on se contentera de construire des tests φ satisfaisant deux propriétés quand le nombre n d'observations tend vers $+\infty$:

1. on dit qu'un test est de niveau asymptotique α quand

$$\forall \theta \in \Theta_0, \quad \limsup_{n \to \infty} \mathbb{P}_{\theta}[\varphi = H_1] \le \alpha$$

2. on dit qu'un test est consistant ou convergeant quand

$$\forall \theta \in \Theta_1, \quad \lim_{n \to \infty} \mathbb{P}_{\theta}[\varphi = H_1] = 1$$



Test de Wald

Le test de Wald : hypothèse nulle simple

On considère le problème de test

$$H_0: \theta = \theta_0 \text{ contre } H_1: \theta \neq \theta_0$$

 $\underline{\mathsf{Hypoth\`ese}}$: on dispose d'un estimateur $\widehat{\theta}_n$ asymptotiquement normal

$$\boxed{\sqrt{n}(\widehat{ heta}_n - heta) \stackrel{d}{
ightarrow} \mathcal{N}ig(0,
u(heta)ig)}$$

et $\theta \mapsto v(\theta) > 0$ est continue.

Sous H_0 (càd quand $Z \sim \mathbb{P}_{\theta_0}$) : on a la convergence

$$\sqrt{rac{n}{
u(\widehat{ heta}_n)}}ig(\widehat{ heta}_n- heta_0ig)\stackrel{d}{\longrightarrow}\mathcal{N}(0,1)$$

Rem. : $v(\widehat{\theta}_n) \leftrightarrow v(\theta_0)$ (pour une hypothèse simple)



Test de Wald : comportement sous H_0 et H_1

sous H_0 :

$$T_n = n \frac{(\widehat{\theta}_n - \theta_0)^2}{v(\widehat{\theta}_n)} \xrightarrow{d} \chi^2(1)$$

sous H_1 : $\forall \theta \in \Theta_1$ (càd $\theta \neq \theta_0$),

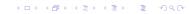
$$T_n \stackrel{\mathbb{P}_\theta}{\longrightarrow} +\infty$$

On va utiliser T_n comme statistique de test et, au vue du comportement de T_n sous H_1 , on considère des tests de la forme

$$\varphi_{\alpha} = \begin{cases}
H_0 & \text{quand } T_n \leq t_{n,\alpha} \\
H_1 & \text{sinon}
\end{cases}$$

Pour déterminer le seuil $t_{n,\alpha}$, on regarde le comportement sous H_0 : soit $q_{1-\alpha}^{\chi^2(1)}$, le quantile d'ordre $1-\alpha$ d'une $\chi^2(1)$, on choisit

$$t_{n,lpha}=q_{1-lpha}^{\chi^2(1)}$$



Propriétés du test de Wald

Proposition

Le test de Wald de l'hypothèse simple $\theta=\theta_0$ contre l'alternative $\theta\neq\theta_0$ basé sur l'estimateur a.n. $\widehat{\theta}_n$ est

ightharpoonup de niveau asymptotique lpha :

$$\mathbb{P}_{\theta_0}\left[\varphi_\alpha = H_1\right] \longrightarrow \alpha$$

• convergeant (ou consistant) : pour tout $\theta \neq \theta_0$

$$\mathbb{P}_{\theta}\left[\varphi_{\alpha}=H_{1}\right]\longrightarrow 1$$



Preuve

- niveau asymptotique α : par construction
- ▶ Contrôle de la puissance : Soit $\theta \neq \theta_0$. On a, sous \mathbb{P}_{θ} ,

$$\frac{(\widehat{\theta}_n - \theta_0)}{\nu(\widehat{\theta}_n)} \xrightarrow{\mathbb{P}_{\theta}} \frac{(\theta - \theta_0)^2}{\nu(\theta)} > 0$$

et comme

$$T_n = n \frac{(\widehat{\theta}_n - \theta_0)}{\nu(\widehat{\theta}_n)}$$

alors $T_n \xrightarrow{\mathbb{P}_{\theta}} +\infty$ et donc

$$\mathbb{P}_{\theta}\left[\varphi_{\alpha}=H_{1}\right]=\mathbb{P}_{\theta}\left[T_{n}>q_{1-\alpha}^{\chi^{2}(1)}\right]\longrightarrow+\infty$$



Test de Wald : hypothèse nulle composite

▶ <u>Même contexte</u> : $\Theta \subset \mathbb{R}^d$ et on dispose d'un estimateur $\widehat{\theta}_n$ asymptotiquement normal :

$$\sqrt{n}(\widehat{\theta}_n - \theta) \xrightarrow{d} \mathcal{N}(0, V(\theta))$$

où $V(\theta)$ est définie positive et continue en θ .

▶ But : Tester $H_0: \theta \in \Theta_0$ contre $H_1: \theta \notin \Theta_0$, où

$$\Theta_0 = \{ \theta \in \Theta, \ g(\theta) = 0 \}$$

et

$$g: \mathbb{R}^d \to \mathbb{R}^m$$

est régulière.



Test de Wald : comportement sous H₀

▶ Hypothèse : le gradient $\nabla g(\theta)$ de g est tel que

$$\theta \in \Theta \mapsto \Sigma_{g}(\theta) = \nabla g(\theta)^{\top} V(\theta) \nabla g(\theta)$$

est continue et inversible en tout point θ .

Proposition

Pour tout $\theta \in \Theta_0$ (i.e. sous H_0), on a :

$$\sqrt{n}g(\widehat{\theta}_n) \stackrel{d}{\longrightarrow} \mathcal{N}(0, \Sigma_g(\theta))$$

•

$$\textit{T}_{\textit{n}} = \textit{ng}(\widehat{\theta}_{n})^{\textit{T}} \Sigma_{\textit{g}}(\widehat{\theta}_{n})^{-1} \textit{g}(\widehat{\theta}_{n}) \overset{\textit{d}}{\longrightarrow} \chi^{2}(\textit{m})$$

▶ Preuve : méthode « delta » multidimensionnelle.

Test de Wald : propriétés

Proposition

Sous les hypothèses précédentes, le test

$$arphi_{lpha} = \left\{ egin{array}{ll} H_0 & \textit{si } T_n \geq q_{1-lpha}^{\chi^2(m)} \ H_1 & \textit{sinon} \end{array}
ight.$$

où $q_{1-\alpha}^{\chi^2(m)}$: quantile d'ordre $1-\alpha$ d'une $\chi^2(m)$, est

• de niveau asymptotique α : $\forall \theta \in \Theta_0$,

$$\mathbb{P}_{\theta}\left[\varphi_{\alpha}=H_{1}\right]\to\alpha$$

▶ Convergeant : $\forall \theta \notin \Theta_0$,

$$\mathbb{P}_{\theta}\left[arphi_{lpha}=\mathit{H}_{1}
ight]
ightarrow1$$



Tests d'adéquation

Problème de test d'adéquation

Situation : On observe un n-échantillon de loi (cdf) F inconnu

$$X_1,\ldots,X_n \overset{i.i.d.}{\sim} F$$

et on se donne une loi (cdf) F_0 (ex. : F_0 cdf d'une $\mathcal{N}(0,1)$)

But: Tester

$$H_0: F = F_0$$
 contre $H_1: F \neq F_0$

Ce problème de test est appelé : problème de test d'adéquation



Test (d'adéquation) de Kolmogorov-Smirnov

Test de Kolmogorov-Smirnov

▶ Rappel : Si la fonction de répartition F est continue alors

$$\sqrt{n} \|\widehat{F}_n - F\|_{\infty} \xrightarrow{d} K$$

où la loi de K ne dépend pas de F (cf. cours1)

Proposition (Test de Kolmogorov-Smirnov)

Soit $q_{1-\alpha}^K$ tel que $\mathbb{P}\left[K>q_{1-\alpha}^K\right]=\alpha$. Le test défini par

$$\varphi_{\alpha} = \begin{cases} H_0 & \text{si } T_n \leq q_{1-\alpha}^K \\ H_1 & \text{sinon} \end{cases} \text{ pour } T_n = \sqrt{n} ||\widehat{F}_n - F_0||_{\infty}$$

est de niveau asymptotique $\alpha: \mathbb{P}_{F_0}\left[\varphi_\alpha = H_1\right] \to \alpha$ et consistant :

$$\forall F \neq F_0 : \mathbb{P}_F \left[\varphi_{\alpha} = H_1 \right] \to 1$$



Tests d'adéquation du χ^2

Test du Chi-deux

▶ X variable qualitative : $X \in \{1, ..., d\}$

$$\mathbb{P}\left[X=\ell\right]=p_\ell,\ \ell=1,\ldots d.$$

- ▶ La loi de X est caratérisée par $\mathbf{p} = (p_1, \dots, p_d)^T$
- Notation

$$\mathcal{M}_d = \left\{ \mathbf{p} = (p_1, \dots, p_d)^T : p_\ell \geq 0, \sum_{\ell=1}^d p_\ell = 1
ight\}$$

▶ Objectif : A partir d'un *n*-échantillon $X_1, \ldots, X_n \overset{i.i.d.}{\sim} \mathbf{p}$, et d'une loi $\mathbf{q} \in \mathcal{M}_d$ donnée on veut tester

$$H_0: \mathbf{p} = \mathbf{q} \text{ contre } H_1: \mathbf{p} \neq \mathbf{q}$$



Construction « naturelle » d'un test

Comparaison des fréquences empiriques

$$\widehat{p}_{n,\ell} = \frac{1}{n} \sum_{i=1}^{n} I(X_i = \ell)$$
 proche de q_ℓ , $\ell = 1, \ldots, d$?

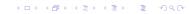
▶ Loi forte des grands nombres : sous H_0 ,

$$(\widehat{p}_{n,1},\ldots,\widehat{p}_{n,d}) \stackrel{\textit{p.s.}}{\longrightarrow} (p_1,\ldots,p_d) = \mathbf{p}.$$

Théorème central-limite?

$$\mathbf{U}_n(\mathbf{p}) = \sqrt{n} \left(\frac{\widehat{p}_{n,1} - p_1}{\sqrt{p_1}}, \dots, \frac{\widehat{p}_{n,d} - p_d}{\sqrt{p_d}} \right) \xrightarrow{d} ?$$

► Composante par composante oui. Convergence globale plus délicate (coordonnées dépendantes).



Statistique du Chi-deux

Proposition

Si les composantes de **p** sont toute non-nulles

ightharpoonup On a la convergence en loi sous $\mathbb{P}_{\mathbf{p}}$

$$\boldsymbol{U}_n(\boldsymbol{p}) \stackrel{d}{\longrightarrow} \mathcal{N}\big(\boldsymbol{0}, \boldsymbol{V}(\boldsymbol{p})\big)$$

avec
$$V(\mathbf{p}) = \mathrm{Id}_d - \sqrt{\mathbf{p}} (\sqrt{\mathbf{p}})^T$$
 et $\sqrt{\mathbf{p}} = (\sqrt{p_1}, \dots, \sqrt{p_d})^T$

De plus

$$\|\mathbf{U}_n(\mathbf{p})\|_2^2 = n \sum_{\ell=1}^d \frac{(\widehat{p}_{n,\ell} - p_\ell)^2}{p_\ell} \stackrel{d}{\longrightarrow} \chi^2(\mathbf{d} - \mathbf{1})$$



Preuve de la normalité asymptotique

▶ Pour i = 1, ..., n et $1 \le \ell \le d$, on pose

$$Y_\ell^i = rac{1}{\sqrt{
ho_\ell}}ig(I(X_i = \ell) -
ho_\ellig)$$

Les vecteurs $\mathbf{Y}_i = (Y_1^i, \dots, Y_d^i)$ sont i.i.d. et

$$\mathbf{U}_n(\mathbf{p}) = \frac{1}{\sqrt{n}} \sum_{i=1}^n \mathbf{Y}_i,$$

$$\mathbb{E}\left[Y_{\ell}^{i}\right]=0,\ \mathbb{E}\left[(Y_{\ell}^{i})^{2}\right]=1-p_{\ell},\ \mathbb{E}\left[Y_{\ell}^{i}Y_{\ell'}^{i}\right]=-(p_{\ell}p_{\ell'})^{1/2}$$

On applique le TCL vectoriel



Convergence de la norme au carré

- ▶ On a donc, sous H_0 , $\mathbf{U}_n(\mathbf{p}) \stackrel{d}{\longrightarrow} \mathcal{N}(0, V(\mathbf{p}))$
- ▶ et aussi, par Cochran,

$$\|\mathbf{U}_n(\mathbf{p})\|_2^2 \stackrel{d}{\longrightarrow} \|\mathcal{N}\big(0,V(\mathbf{p})\big)\|_2^2 \sim \chi^2\big(\mathrm{Rang}\big(V(\mathbf{p})\big)\big)$$

 $V(\mathbf{p}) = \mathrm{Id}_d - \sqrt{\mathbf{p}} (\sqrt{\mathbf{p}})^T$ est la projection orthogonale sur $\mathrm{vect} \{\sqrt{\mathbf{p}}\}^\perp$ qui est de dimension d-1



Test d'adéquation du χ^2

• « distance » du χ^2 :

$$\chi^2(\mathbf{p},\mathbf{q}) = \sum_{\ell=1}^d rac{(p_\ell-q_\ell)^2}{q_\ell}.$$

• Avec ces notations $\|\mathbf{U}_n(\mathbf{p})\|_2^2 = n\chi^2(\widehat{\mathbf{p}}_n, \mathbf{p})$.

Proposition

Pour $\mathbf{q} \in \mathcal{M}_d$ le test défini par

$$\varphi_{\alpha} = \begin{cases} H_0 & \text{si } n\chi^2(\widehat{\mathbf{p}}_n, \mathbf{p}) \le q_{1-\alpha}^{\chi^2(d-1)} \\ H_1 & \text{sinon} \end{cases}$$

est de niveau asymptotique lpha et consistant pour tester

$$H_0: \mathbf{p} = \mathbf{q}$$
 contre $H_1: \mathbf{p} \neq \mathbf{q}$



Exemple de mise en oeuvre : expérience de Mendel

▶ Soit *d* = 4 et

$$\mathbf{q} = \left(\frac{9}{16}, \frac{3}{16}, \frac{3}{16}, \frac{1}{16}\right).$$

• fréquence empirique : n = 556

$$\widehat{\mathbf{p}}_{556} = \frac{1}{556}(315, 101, 108, 32).$$

ightharpoonup Calcul de la statistique du χ^2

$$556 imes \chi^2(\widehat{\mathbf{p}}_{556}, \mathbf{q}) = 0,47.$$

- On a $q_{95\%}^{\chi^2(3)} = 7.815$.
- ▶ Conclusion : Puisque 0.47 < 7.815, on accepte l'hypothèse $\mathbf{p} = \mathbf{q}$ au niveau $\alpha = 5\%$. De plus, la p-value vaut 0.93 : très grand niveau de confiance en l'acceptation.



Test d'indépendance du χ^2

Problèmatique

 $\frac{\text{donn\'ees/mod\`ele}}{\text{al\'eatoires qualitatives}}$: on observe un n-échantillon de couples de variables

$$(X_1, Y_1), \ldots, (X_n, Y_n) \stackrel{i.i.d.}{\sim} (X, Y) \in \{1, \ldots, d_1\} \times \{1, \ldots, d_2\}$$

La loi \mathbf{p} de (X, Y) appartient à

$$\mathcal{M}_{d_1,d_2} = \left\{ \mathbf{p} = (p_{\ell,\ell'})_{\substack{1 \leq \ell \leq d_1 \ 1 \leq \ell' \leq d_2}} : 0 \leq p_{\ell,\ell'}, \sum_{\ell,\ell'} p_{\ell,\ell'} = 1
ight\}$$

On considère le problème de test suivant :

$$\textit{H}_0: \mathbb{P}_{(X,Y)} = \mathbb{P}_X \otimes \mathbb{P}_Y \text{ contre } \textit{H}_1: \mathbb{P}_{(X,Y)} \neq \mathbb{P}_X \otimes \mathbb{P}_Y$$



principe du test d'indépendance du χ^2 (1/2)

On a l'équivalence :

$$\mathbb{P}_{(X,Y)} = \mathbb{P}_X \otimes \mathbb{P}_Y \Leftrightarrow \forall \ell, \ell', p_{\ell,\ell'} = p_{\ell,\bullet} \times p_{\bullet,\ell'}$$

οù

$$p_{\ell,\ell'} = \mathbb{P}[(X,Y) = (\ell,\ell')], \quad p_{\ell,\bullet} = \mathbb{P}[X = \ell], \quad p_{\bullet,\ell'} = \mathbb{P}[Y = \ell']$$

On estime ces quantités par leurs fréquences empiriques :

$$\hat{p}_{\ell,\ell'}^{(n)} = \frac{1}{n} \sum_{i=1}^{n} I[(X_i, Y_i) = (\ell, \ell')]$$

$$\hat{p}_{\ell,\bullet}^{(n)} = \frac{1}{n} \sum_{i=1}^{n} I[X_i = \ell] \quad \hat{p}_{\bullet,\ell'}^{(n)} = \frac{1}{n} \sum_{i=1}^{n} I[Y_i = \ell']$$

principe du test d'indépendance du χ^2 (2/2)

Idée:

- 1. On aimerait pouvoir tester si la loi du couple (X, Y) est égale à $\mathbb{P}_X \otimes \mathbb{P}_Y$, on ferait alors un test d'adéquation.
- 2. Mais, on ne connaît pas la loi $\mathbb{P}_X \otimes \mathbb{P}_Y$, on va donc l'estimer par

$$ig(\hat{p}_{\ell,ullet}^{(n)} imes\hat{p}_{ullet,\ell'}^{(n)}ig)_{\substack{1\leq\ell\leq d_1\1\leq\ell'\leq d_2}}$$

3. on peut alors faire un test d'adéquation du χ^2 par rapport à cette loi estimée. La statistique de test est

$$n\chi^2\Big((\hat{p}_{\ell,\ell'}^{(n)})_{\ell,\ell'},(\hat{p}_{\ell,\bullet}^{(n)}\times\hat{p}_{\bullet,\ell'}^{(n)})_{\ell,\ell'}\Big)$$



Comportement de la statistique de test sous H_0 et sous H_1

On utilise la statistique de test

$$T_n = n\chi^2\Big((\hat{p}_{\ell,\ell'}^{(n)})_{\ell,\ell'}, (\hat{p}_{\ell,\bullet}^{(n)} \times \hat{p}_{\bullet,\ell'}^{(n)})_{\ell,\ell'}\Big)$$

pour construire le test d'indépendance du χ^2 . Son comportement sous les deux hypothèses est donné par :

Sous H_0 :

$$T_n \stackrel{d}{\longrightarrow} \chi^2((d_1-1)(d_2-1))$$

Sous H_1 :

$$T_n \xrightarrow{p.s.} +\infty$$

On regarde donc des tests de la forme

$$\varphi_{\alpha} = \begin{cases} H_0 & \text{si } T_n \leq t_{n,\alpha} \\ H_1 & \text{sinon} \end{cases}$$

et le seuil $t_{n,\alpha}$ est donné par la loi limite de T_n sous H_0



test d'indépendance du χ^2

Theorem

Pour tout $\alpha \in (0,1)$, le test

$$\varphi_{\alpha} = \begin{cases} H_0 & \text{si } T_n \leq q_{1-\alpha}^{\chi^2((d_1-1)(d_2-1))} \\ H_1 & \text{sinon} \end{cases}$$

où $q_{1-\alpha}^{\chi^2((d_1-1)(d_2-1))}$ est le quantile d'ordre $1-\alpha$ d'une $\chi^2((d_1-1)(d_2-1))$, est de niveau asymptotique α et consistant



Exemple: test d'indépendance entre revenus et nombre d'enfants

Catégories de revenus : I (faible) à IV (élevé)

nb. enfants		П	Ш	IV	total ligne
0	2161	3577	2184	1636	9558
1	2755	5081	2222	1052	11110
2	936	1753	640	306	3635
3	225	419	96	38	778
\geq 4	39	98	31	14	182
tot. col.	6116	10928	5173	3016	25263

On obtient:

$$T_{n} = n\chi^{2} \left((\hat{p}_{\ell,\ell'}^{(n)})_{\ell,\ell'}, (\hat{p}_{\ell,\bullet}^{(n)} \times \hat{p}_{\bullet,\ell'}^{(n)})_{\ell,\ell'} \right)$$

$$= \sum_{\substack{\ell \in \{0,1,2,3," \geq 4"\}\\ \ell' \in \{1,H,HI,IV\}}} \frac{(\hat{p}_{\ell,\ell'}^{(n)} - \hat{p}_{\ell,\bullet}^{(n)} \hat{p}_{\bullet,\ell'}^{(n)})^{2}}{\hat{p}_{\ell,\bullet}^{(n)} \hat{p}_{\bullet,\ell'}^{(n)}} = 568.5$$

Table des quantiles d'une $\chi^2(12)$

On a ici $(d_1 - 1)(d_2 - 1) = (5 - 1)(4 - 1) = 12$. On regarde alors les quantiles

$$q_{1-\alpha}^{\chi^2(12)}$$

α	0,2	0,1	0,05	0,02	0,01	0,005	0,001
$q_{1-lpha}^{\chi^2(12)}$	15,8	18,5	21,0	24,0	26,2	28,2	32,9

Python:

- > from scipy.stats import chi2
- > 1-chi2.cdf(100, 12)
- 5.5e-16

lci la statistique du test vaut $T_n = 568.5$ donc la p-value est plus petite que $5.5.10^{-16}$. Alors on rejete avec confiance. Il y a donc une très forte dépendance entre le nombre d'enfants et les revenus.

